

Análise de Sentimentos Aplicada à Política

Lucas Romão Silva

Prof Dr. Roberto Hirata Jr.

18 de novembro de 2017

Sumário

1	Introdução	1
2	Revisão Bibliográfica	3
3	<i>Machine Learning</i> e Análise de Sentimentos	5
3.1	Considerações	5
3.2	Contextualização	5
3.3	Logistic Regression	6
3.3.1	Método do Gradiente	7
3.3.2	Método de Newton-Raphson	9
3.3.3	Extensão para o caso de várias classes	9
3.4	Support Vector Machine	11
3.4.1	Extensão ao caso de multiclases	14
3.5	Análise de Sentimentos	15
3.5.1	Análise de <i>Tweets</i> de política	16
3.5.2	Obtendo um vetor de <i>features</i>	17
3.5.3	Classificação Manual da Opinião	18
4	Experimentos	23
4.1	Descrição dos experimentos	23
4.2	Análise Exploratória	23
4.3	Métricas avaliadas	23

Capítulo 1

Introdução

Capítulo 2

Revisão Bibliográfica

Diversos estudos recentes têm sido realizados na área de análise de sentimentos. Medhat (2014)[1], sumariza diversos estudos feitos dividindo-os em abordagens (usando técnicas de aprendizado de máquina, dicionário léxico ou híbrida) e em objetivos (classificação de sentimentos, detecção de emoções etc).

Em Pak (2010)[2] é analisado o uso de um corpus compostos de tuítes para a realização de tarefas de análise de sentimentos e mineração de opinião. Nesse estudo é construído um classificador de sentimentos para as opiniões associadas aos tuítes coletados e é discutido desafios encontrados na hora de desenvolver um classificador para o corpus.

Outros estudos, assim como este trabalho, têm como foco o uso de análise de sentimentos aplicados à política utilizando tuítes como o corpus. Em Tumasjan et. al (2010) é estudado se é possível utilizar o Twitter para obter uma previsão para os resultados de uma eleição tendo como base as eleições do parlamento alemão realizadas em 2009.

Risquandl e Petković (2013)[3] realizam experimentos tendo como cenário as eleições presidenciais estadounidenses de 2012 para classificar sentimentos dos usuários do twitter, porém diferente dos outros trabalhos anteriormente mencionados, esse estudo utiliza técnicas de part of speeching tagging para identificar sobre quem os tuítes se referem e, a partir disso, classifica o sentimento baseado a aspectos dessa entidade, no caso pautas eleitorais que foram fortemente discutidas como casamento de pessoas do mesmo gênero, teaparty etc.

Bakliwal et. all (2013)[4] realiza um estudo semelhante ao deste trabalho a classificação de opinião tendo como base três classes (positivo, negativo ou neutro) a cerca de tuítes coletados sobre as eleições gerais da Irlanda em fevereiro de 2011. A diferença entre os trabalhos é que Bakliwal associa a cada partido um sentimento associado a um dos partidos.

Capítulo 3

Machine Learning e Análise de Sentimentos

3.1 Considerações

Ao longo deste capítulo usaremos n para se referir à quantidade de elementos do conjunto de entrada, cada entrada i é um vetor $x_i \in \mathbb{R}^m$. O conjunto de entrada será referida como X durante as descrições do algoritmo e assim cada entrada será dada tanto como X_i como x_i . Para cada i associaremos duas variáveis t_i e y_i que se referem ao valor esperado e ao valor obtido através do treinamento, respectivamente.

A notação $\mathbb{1}_{i=j}$ é uma função indicadora que vale 1 se i é igual a j e 0 caso contrário.

3.2 Contextualização

Os problemas tratados por *Machine Learning* classificam-se de forma geral em três tipos:

- Aprendizado supervisionado: nesse caso tem-se os elementos de entrada e para cada um desses elementos, tem-se associado um rótulo t_i . Nesse caso o modelo deve ser treinado com base nos elementos dados para que se possa prever o rótulo de uma nova entrada;
- Aprendizado não-supervisionado: nesse caso tem-se apenas os elementos de entrada. O objetivo deste tipo de problema é tentar modelar uma distribuição ou estrutura comum entre os dados para que se possa entendê-los melhor;

- Aprendizado semi-supervisionado: nesse último caso alguns elementos possuem um rótulo associado. Problemas desse tipo aplicam técnicas tanto de aprendizado supervisionado como de não-supervisionado.

Neste trabalho será tratado um problema de aprendizado supervisionado que é o da classificação.

Na classificação temos k classes e cada elemento i da entrada é associado a uma classe $t_i = \{1..k\}$. O objetivo do problema da classificação é dado entrada $X = (x_1, x_2, \dots, x_n)$ e $t = (t_1, \dots, t_n)$ treinar um modelo capaz de prever classes para um x qualquer.

Há diversos algoritmos na literatura que se propõem a resolver o problema da classificação. Bishop (2006)[5] enuncia diversos dos algoritmos comumente utilizados para a classificação, cada algoritmo possui seus prós e contras e utiliza diferentes abordagens.

Para este trabalho escolheu-se implementar os algoritmos *Logistic Regression* e *Support Vector Machines*, que será chamado simplesmente de SVM por facilidade.

Tanto para o *Logistic Regression* quanto SVM será explicado a princípio o problema será inicialmente abordado a partir da classificação binária e, a partir dela, será descrito como estender para o problema com mais de duas classes, que será o caso deste trabalho.

3.3 Logistic Regression

O nosso modelo será construído de forma probabilística, isto é, a partir de um discriminante linear $w^T x + w_0$ atribuiremos uma probabilidade de um elemento x pertencer à classe C^1 e, consequentemente a probabilidade de pertencer à classe C^2 é dada por $1 - P(C^1|x)$. O termo w_0 é chamado de viés, e para efeito das contas que serão feitas consideraremos vetores w' e x' da forma $x' = (x, 1)$, $w' = (w, w_0)$ note entretanto que os chamaremos daqui pra frente simplesmente de w e x .

No caso da classificação binária, usaremos que $t_n \in \{0, 1\}$ onde $t_n = 1$ se o elemento pertence à classe C^1 e $t_n = 0$ se pertence à classe C^2 .

A classificação de um elemento será a classe a qual ele tem maior probabilidade de pertencer.

Para utilizarmos nosso discriminante para atribuir as probabilidades, utiliza-se a função sigmóide definida por:

$$\sigma(a) = \frac{1}{1 + \exp(-a)} \quad (3.1)$$

A função sigmóide é usada devido à sua propriedade de mapear todo o conjunto dos números reais dentro do intervalo $[0, 1]$.

Aplicando ao nosso modelo obtêm-se a expressão:

$$P(C^1|x) = y(x) = \sigma(w^T x) \quad (3.2)$$

Importante notar que apesar de utilizarmos o vetor x nas equações, é possível aplicarmos uma transformação linear $\phi : \mathcal{R}^m \rightarrow \mathcal{R}^d$ à entrada x para obtermos $\phi(x)$ e usá-lo no lugar de x . O uso de transformação linear no nosso conjunto de entrada nos permite transformar o domínio para que se obtenha uma separação melhor entre as classes ou até mesmo fazer a redução da dimensão do domínio.

Com essa equação em mãos, nosso objetivo é minimizar o erro na classificação dos dados. Tomamos como erro o negativo do logaritmo da verossimilhança de nossa função que é dada por:

$$E(w) = - \sum_{i=1}^n p(t_i|w) = - \sum_{i=1}^n \{t_i \ln(y_i) + (1 - t_i) \ln(1 - y_i)\} \quad (3.3)$$

A fim de minimizar o erro, utiliza-se métodos de otimização linear (note que por mais que se use uma transformação linear ϕ sobre x nosso problema ainda é linear sobre w).

Dois métodos são comumente usados: método do gradiente e método de Newton-Raphson. Esses métodos são utilizados tanto para o caso da classificação binária quanto o caso da classificação com $k > 2$. A diferença entre um problema e outro será abordada com mais detalhes a seguir.

Uma dúvida natural que surge ao ter que resolver um problema de otimização é o caso de parar o procedimento em um mínimo local ao invés de um mínimo local da função. Entretanto, temos que nossa função $E(w)$ é côncava, isto é, $E(\lambda w + (1 - \lambda)w') = \lambda E(w) + (1 - \lambda)E(w') \forall w, w' \in R^m, \lambda \in [0, 1]$, tal propriedade nos garante que existe um único minimizador.

3.3.1 Método do Gradiente

Para este método, minimiza-se a função objetivo, no caso $E(w)$ utilizando apenas o gradiente da função junto de um passo α . Com ambos valores em mãos, o valor w é atualizado usando a equação:

8CAPÍTULO 3. MACHINE LEARNING E ANÁLISE DE SENTIMENTOS

$$w^{(novo)} = w^{(antigo)} + \alpha \nabla E(w) \quad (3.4)$$

Com $\nabla E(w)$ sendo o gradiente do vetor de pesos. O gradiente é calculado usando o fato de que a derivada da função sigmóide com respeito a um vetor a é dada por:

$$\frac{d\sigma}{da} = \sigma(1 - \sigma) \quad (3.5)$$

Usando 3.5 tem-se a seguinte equação para o gradiente:

$$\nabla E(w) = X^T(y - t) \quad (3.6)$$

Com $y = (y_1, \dots, y_n)$ e $t = (t_1, \dots, t_n)$ onde $y_n = P(C^1|x_n) = \sigma(w^T x)$ e t_n tal qual assumido no começo da seção.

O algoritmo de atualização do vetor de pesos descrito a seguir vale tanto para o método do gradiente quanto para o de Newton-Raphson, portanto para o segundo será focado apenas nas diferenças entre os dois.

Algorithm 1 Logistic Regression usando método do gradiente

Input: Matriz $X \in \mathbb{R}^{n \times m}$, vetor de rótulos $t \in \{0, 1\}^n$

Output: Vetor de pesos $w \in \mathbb{R}^m$

```

1: iteracao  $\leftarrow$  0
2:  $w \leftarrow 0$ 
3: while  $|E(w)^{(iteracao)} - E(w)^{(iteracao-1)}| \geq \epsilon$  and  $iteracao < maxIteracoes$ 
   do
4:    $y \leftarrow (\sigma(w^T x_1), \sigma(w^T x_2), \dots, \sigma(w^T x_n))^T$ 
5:    $\nabla E(w) \leftarrow X^T(y - t)$ 
6:    $w \leftarrow w - \alpha \nabla E(w)$ 
7:    $E(w)^{(iteracao)} \leftarrow -\sum_{i=1}^n \{t_n \ln(y_n) + (1 - t_n) \ln(1 - y_n)\}$ 
8:    $iteracao \leftarrow iteracao + 1$ 
9: end while
```

Importante notar que em 3 tem-se duas condições de paradas do algoritmo que são o número de iterações e a diferença da diminuição da função objetivo for menor do que um dado ϵ . Tais condições são chamadas de condições de

convergência e nos garantem que chegamos a um valor suficientemente próximo do ótimo, uma vez que atingir este valor pode exigir um número muito alto de iterações o que acarreta em grande custo computacional. Na implementação do algoritmo, escolheu-se um valores padrão para ϵ e $maxIteracoes$ como 10^{-4} e 200 respectivamente.

A quantidade de iterações necessárias para a convergência é influenciada fortemente pela escolha de α , pois a escolha de um valor pequeno para α acarretaria em muitas iterações para convergir ao passo que um valor muito grande pode fazer com que o algoritmo pare num valor distante do ótimo.

3.3.2 Método de Newton-Raphson

Vimos em 3.3.1 que o método do gradiente apesar de implementação simples pode levar muito tempo para resolver o problema.

O método de Newton-Raphson acaba convergindo mais rápido do que o método do gradiente, contudo ao custo de uma maior complexidade devido à necessidade de calcular outros elementos.

A atualização agora é feita seguindo a equação

$$w^{(novo)} = w^{(antigo)} - H^{-1} \nabla E(w) \quad (3.7)$$

Onde H é a matriz Hessiano da função erro, que é calculado usando $H = \nabla \nabla E(w) = X^T R X$ onde R é uma matriz diagonal $n \times n$ onde as entradas da diagonal principal valem $R_{kk} = y_k(1 - y_k)$. Substituindo os valores de H e usando 3.6 em 3.7 obtemos

$$\begin{aligned} w^{(novo)} &= w^{(antigo)} - (X^T R X)^{-1} \nabla E(w) \\ &= (X^T R X)^{-1} [(X^T R X) w^{(antigo)} - X^T (y - t)] \end{aligned} \quad (3.8)$$

3.3.3 Extensão para o caso de várias classes

Diversas abordagens podem ser usadas para resolver o problema multiclasse, no caso será usado diversos discriminantes y_k com $k = \{1, \dots, K\}$ com K sendo o total de classes. Assim nosso vetor w agora é uma matriz $W \in \mathbb{R}^{m \times k}$. Outra representação que usaremos para o algoritmo será $W = (w_1, \dots, w_k)$ com $w_i \in \mathbb{R}^{1 \times mk}$.

Quanto à codificação do vetor de rótulos, segue-se a codificação dada em Bishop (2006)[5] de $1 - K$, na codificação tem-se que $t_n \in \{0, 1\}^k$ com $t_{nk} = 1$ se o elemento n pertencer à classe k e 0 nas demais entradas.

Quanto a função de probabilidade que desejamos estimar, utiliza-se a função *softmax* que é dada pela equação:

$$P(C^k|x_n) = y_{nk} = \frac{\exp(w_k^T x_n)}{\sum_j \exp(w_j^T x_n)} \quad (3.9)$$

Que nos dá verossimilhança e a seguinte função de erro, obtida tomando o negativo do logaritmo da verossimilhança.

$$P(T|w_1, \dots, w_k) = \prod_{i=1}^n \prod_{j=1}^k P(C^j|x_i)^{t_{ij}} = \prod_{i=1}^n \prod_{j=1}^k y_{ij}^{t_{ij}}$$

$$E(W) = - \sum_{i=1}^n \sum_{j=1}^k t_{ij} \ln(y_{ij})$$

Novamente nesse caso pode-se encontrar o valor de W que minimize $E(W)$ usando os dois métodos discutidos em 3.3.1 e 3.3.2, porém agora temos que a derivada com respeito a cada $w_k^T x$ vale:

$$\frac{\partial y_k}{\partial (w_j^T x)} = y_k (\mathbb{1}_{k==j} - y_j) \quad (3.10)$$

Usando essa representação de W como um vetor, podemos calcular o vetor gradiente onde a derivada com respeito a cada w_j é dada pela equação:

$$\nabla_{w_j} E(W) = X^T (Y_j - T_j) \quad (3.11)$$

Com Y_j e T_j correspondendo, respectivamente, às j -ésimas colunas de Y e T .

Com o gradiente em mãos já temos o que é necessário para o método do gradiente e a atualização seria feita da forma $W^{(novo)} = W^{(antigo)} - \alpha \nabla E(W)$.

Para aplicarmos o método de Newton-Raphson, seria necessário computarmos o Hessiano que nesse caso seria uma matriz $m * k \times m * k$ com cada bloco j, i contendo uma matriz $m \times m$ calculada pela equação:

$$\nabla_{w_i} \nabla_{w_j} E(W) = - \sum_{k=1}^n y_{ki} (\mathbb{1}_{i=j} - y_{kj}) X_k^T X_k \quad (3.12)$$

Onde X_k é a k -ésima linha de X . Com essas equações em mãos nossa atualização de W seria feita usando a fórmula $W^{(novo)} = W^{(antigo)} - H^{-1} \nabla E(W)$.

A classificação de um novo x é feita a partir do cálculo de $P(C^k|x) = y_k(x), \forall k = \{1, \dots, k\}$.

A classe de x é dada pelo k que tiver a maior probabilidade sobre os demais.

3.4 Support Vector Machine

Assim como fizemos com o logistic regression, começaremos com a definição para o caso binário e depois iremos estender para mais de uma classe. Nesse caso nossas classes serão $t_n \in \{-1, 1\}$ onde $t_n = 1$ se x pertence à classe C^1 e $t_n = -1$ se x pertence à classe C^2 .

No algoritmo SVM a classificação é feita a partir de um discriminante linear da forma

$$y(x) = w^T x + b \quad (3.13)$$

Tal y é chamado de superfície de decisão e a classificação é baseada no sinal de y . Se $y(x) > 0$, x é atribuído à classe C^1 , caso contrário é atribuído à classe C^2 .

Porém ao invés de procurarmos um w que separe perfeitamente todas as classes (que não necessariamente existe), nosso objetivo é maximizar a margem do discriminante linear, isto é, a menor distância de um ponto à superfície. A distância de um ponto à superfície é dado pela fórmula

$$\frac{[t_n(w^T x_n + b)]}{||w||} \quad (3.14)$$

Na descrição inicial do problema vamos tratar o caso com o conjunto X linearmente separável, o que indica que é possível obter uma superfície que separe sem erro todas as classes para, em seguida, tratarmos o caso real que é o do conjunto que não é linearmente separável. O fato de o conjunto ser linearmente separável nos garante que $t_n y(x_n) > 0 \forall n$.

$$\operatorname{argmax}_{x,b} \left\{ \frac{1}{\|w\|} \min_n [t_n(w^T x_n + b)] \right\} \quad (3.15)$$

Podemos ajustar w e b de forma a termos que $t_n(w^T x_n + b) = 1$ para o ponto mais próximo da margem e $t_n(w^T x_n + b) \geq 1, \forall n$. Com esse reajuste temos que nosso problema de encontrar um vetor de pesos de margem maximizada seria de maximizar $\frac{1}{\|w\|}$ que é equivalente ao problema de otimização quadrática:

$$\begin{aligned} & \operatorname{argmin}_{w,b} \|w\|^2 \\ & \text{sujeito a } t_k(w^T x_k + b), \quad k = 1, \dots, n \end{aligned} \quad (3.16)$$

Agora iremos supor que não necessariamente nossa entrada não é linearmente separável, isto é, não existe uma superfície de decisão que separe perfeitamente as duas classes. Assim iremos permitir que alguns valores estejam classificados incorretamente, para isso será necessário suavizarmos nossa margem penalizando cada uma das entradas incorretamente classificadas. Cortes e Vapnik (1995)[6] descrevem a penalização através da introdução de variáveis de folga $\xi_n \geq 0$ para cada elemento de X . Um elemento corretamente classificado terá $\xi_n = 0$, os demais pontos têm $\xi_n = |t_n - y(x_n)|$.

Com isso nossa restrição de $t_n y(x_n) \geq 1$ é modificada e tem-se $t_n y(x_n) \geq 1 - \xi_n \forall n$.

O valor de ξ_n assim nos indica três possíveis casos:

- Se $\xi_n = 0$, x_n está corretamente classificado e se encontra ou na margem ou do lado correto dela.
- Se $0 < \xi_n \leq 1$, x_n está corretamente classificado e se encontra entre a margem e a superfície.
- Se $\xi_n > 1$, x_n não está classificado corretamente.

A função objetivo agora precisa conter os valores de ξ e para isso colocamos uma constante $C > 0$ que define a compensação entre a penalização das variáveis de folga e a margem. Com isso temos o seguinte problema de otimização quadrática:

$$\begin{aligned} & \operatorname{argmin}_{w,b,\xi} C \sum_{i=1}^n \xi_i + \frac{1}{2} \|w\|^2 \\ & \text{sujeito a } t_k(w^T x_k + b) \geq 1 - \xi_k, \quad k = 1, \dots, n \end{aligned} \quad (3.17)$$

Para implementar o SVM basta então resolver o problema de otimização quadrática acima. Isto é feito seguindo os seguintes passos

1. Introduz-se multiplicadores de Lagrange α_n e μ_n e obtem-se o Lagrangiano com as restrições

$$L(w, b, \xi) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i \{t_i(w^T x_i + b) - 1 + \xi_i\} - \sum_{i=1}^n \mu_i \xi_i \quad (3.18a)$$

$$\alpha_n \geq 0 \quad (3.18b)$$

$$t_n y(x_n) - 1 + \xi_n \geq 0 \quad (3.18c)$$

$$\alpha_n \{t_n(w^T x_n + b) - 1 + \xi_n\} = 0 \quad (3.18d)$$

$$\mu_n \geq 0 \quad (3.18e)$$

$$\mu_n \xi_n = 0 \quad (3.18f)$$

2. Derivamos o lagrangiano com respeito a w , b e ξ e igualamos a 0 para obtermos os valores ótimos para essas variáveis e, assim obtemos os seguintes valores:

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i t_i x_i \quad (3.19)$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i t_i = 0 \quad (3.20)$$

$$\frac{\partial L}{\partial \xi} = 0 \Rightarrow \alpha_n = C - \mu_n \quad (3.21)$$

3. Com isso em mãos, resolve-se não o problema primal e sim o dual (utiliza-se aqui o fato de que se as condições mencionadas no item anterior são satisfeitas, tem-se que vale a dualidade forte e o valor ótimo de ambas as funções coincide). O dual é dado pelo problema

$$\begin{aligned} \min_{\alpha} \quad & \tilde{L}(\alpha) = \sum_{i=1}^n \alpha_i - 1/2 \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j t_i t_j k(x_i, x_j) \\ \text{sujeito a} \quad & 0 \leq \alpha_i \leq C, i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i t_i = 0 \end{aligned} \quad (3.22)$$

No problema a cima é importante destacar a expressão $k(x_i, x_j)$, essa expressão é um *Kernel* que é uma função onde $k(x, x') = \phi(x)^T \phi(x')$ com ϕ sendo alguma transformação linear. Tal qual no caso da regressão logística, essas transformações são usadas para mudar o domínio da entrada x .

4. Acha-se o valor de b usando a fórmula:

$$b = \frac{1}{N_{\mathcal{M}}} \sum_{n \in \mathcal{M}} \left(t_n - \sum_{m \in \mathcal{S}} \alpha_m t_m k(x_n, x_m) \right) \quad (3.23)$$

Com \mathcal{M} sendo o conjunto de pontos que satisfazem $0 < \alpha_n < C$ e \mathcal{S} o conjunto de vetores de suporte (pontos que possuem $\alpha_n > 0$ e, conseqüentemente, contribuem para a classificação do modelo).

Uma vez resolvido o problema dual e encontrado valor de b , podemos classificar um novo x usando o sinal do discriminante $y(x)$ dado por

$$y(x) = \sum_{i=1}^n \alpha_i t_i k(x, x_i) + b = \sum_{n \in \mathcal{S}} \alpha_n t_n l(x, x_n) + b \quad (3.24)$$


3.4.1 Extensão ao caso de multiclass

Diversas abordagens são possíveis para o caso de multiclass. A escolhida entre elas foi o método intuitivo chamado *One-versus-all* (OVA). Nesse método é construído K classificadores, com K sendo o número de classes. Cada classificador y_k define uma superfície de decisão que separa a classe k das demais (por isso o nome *One-versus-all*). Um novo x tem sua classe dada pela que o classificador y_k tem maior valor, isto é


$$y(x) = \underset{k}{\operatorname{argmax}} y_k(x) \quad (3.25)$$

Portanto a classificação multiclass se utiliza de todos os recursos já apresentados no caso binário o que torna simples a construção do classificador.


Na imagem abaixo é mostrado a ideia por trás do método OVA nele a classe C^1 é dada pelos círculos, C^2 pelos triângulos e C^3 pelas cruzeiras. As figuras em vermelho em cada classificador são os pontos onde $t_n = -1$.




(a) Classes originais



(b) Classificador para a classe 1



(c) Classificador para a classe 2



(d) Classificador para a classe 3

3.5 Análise de Sentimentos

O campo de análise de sentimentos, também conhecido como mineração de opinião é uma área da ciência da computação que analisa as opiniões, sentimentos e atitudes das pessoas em relação a uma entidade (Bing Liu, 2012)[7]. Uma entidade pode ser definida como o sujeito ao qual está se observando as opiniões, seja ela uma pessoa, instituição ou produto.

A área possui uma diversa gama de aplicações, dentre elas, a área de classificação de sentimentos que através do uso de informações subjetivas contidas num texto avalia qual a opinião relacionada ao mesmo.

Classificação de sentimentos teve um crescimento devido à expansão da Web 2.0 que fez com que as pessoas manifestassem suas opiniões e sentimentos através de blogs, fóruns, redes sociais e páginas de reviews de produtos que, conseqüentemente fez com que empresas e pessoas de interesse tivessem um acesso mais aberto e fácil a essas opiniões. O fácil acesso às opiniões dos usuários junto com o grande volume delas tornou a análise manual um processo muito custoso, tornando necessário recorrer a métodos automatizados para a análise e sumarização desses dados que acabou por fim impulsionando estudos na área (Petković e Ringsquandl, 2013)[3].

Bing Liu, 2012[7] divide as formas de classificar sentimentos em um do-

cumento pode se dividir em quatro formas:

- Entidade: um produto, pessoa sobre o qual o texto se refere, seja direta ou indiretamente. Nessa tarefa procura-se analisar se a opinião do texto em torno de uma entidade é positiva ou não.
- Aspecto: características sobre uma entidade. Por exemplo se temos uma entidade que é um produto, aspectos de um produto poderiam ser material ou preço. Nessa forma procura-se avaliar a opinião acerca de cada um dos aspectos.
- Sentença: esse tipo de análise trabalha com o sentimento associado a cada sentença de um documento.
- Documento: nesse caso analisa-se o sentimento associado a um documento como um todo, tratando de uma forma mais genérica em relação aos demais.

Comum a todas as formas de se analisar as opiniões de um documento é que o uso dos métodos para obter a opinião. Há duas abordagens para esse problema de classificação: a de aprendizado de máquina (que iremos utilizar nesse trabalho) que se consiste do uso de algoritmos de classificação em conjunto com técnicas de processamento de texto (que será explicado nas próximas seções) e a abordagem com um dicionário léxico onde a análise é feita baseada na pontuação entre palavras positivas e negativas contidas no documento (Medhat et al., 2014) [1].

No caso desse trabalho, foi escolhido a análise em torno do documento / sentença (devido à estrutura dos *tweets* tem-se que os documentos são, em sua maioria, compostos por apenas uma sentença).

3.5.1 Análise de *Tweets* de política

Dentre os domínios de aplicação da classificação de sentimentos, escolheu-se como domínio o escopo político. Nesse caso, temos que as entidades nos documentos são constituídas por políticos e projetos de lei. E neste trabalho será analisado a análise de *tweets*.

O twitter desde as eleições presidenciais estadunidenses de 2008 mostrou influência na decisão das eleições evidenciado pela campanha online realizada pela equipe do candidato Barack Obama (Petković e Ringsquandl, 2013)[3]. Desde então, a rede social tem sido usada não só para a campanha de políticos, mas também para a avaliação da opinião em relação às medidas tomadas por eles.

A escolha dos *tweets* foi feita tendo em vista o uso da rede social para expressar opiniões sobre diversos assuntos, incluindo política.

3.5.2 Obtendo um vetor de *features*

Para realizar a extração das informações do texto, existe uma etapa de pré-processamento na qual cada texto é transformado num vetor numérico para então ser processado por algum algoritmo de classificação. Neste trabalho foi escolhido usar o modelo *bag of words* (BOW). No modelo, é construída uma matriz de entrada onde cada linha i representa um documento (texto sobre o qual quer extrair a opinião) e as colunas representam a frequência de um termo, o conjunto de todos os textos é chamado de *corpus*.

Uma alternativa ao BOW seria o modelo de N-grama, nele os termos não são apenas as palavras, mas um conjunto de n palavras juntas, o que traz mais informação pelo fato de juntar substantivo e verbo, substantivo e adjetivo, por exemplo, entretanto acaba gerando um vetor de *features* ainda maior que, consequentemente, faz com que os algoritmos demorem mais para convergir. A escolha pelo BOW foi tida baseada no compromisso entre desempenho e performance do algoritmo.

Antes de obter um vetor numérico, é feito um pré-processamento no documento removendo artigos, adicionando espaços antes e depois de pontuações e transformando em um vetor de tokens. Uma vez que foi obtido o vetor de *tokens*, é removido todo elemento que seja apenas espaço e pontuação. Em seguida, monta-se uma nova *string* juntando todas as *tokens* usando espaços para então montar um vetor de frequência a partir do novo *corpus*.

A frequência pode ser medidas simples como a quantidade de vezes em que um termo j aparece no documento i ou se o termo j aparece no documento i (nesse caso cada vetor de entrada seria um vetor binário) bem como pode ser uma medida mais complexa como tf-idf (*term frequency - inverse document frequency*). A relação entre os métodos de computar a frequência e o desempenho dos algoritmos de classificação serão exibidas no capítulo seguinte.

O método tf-idf baseia-se na frequência de cada termo ponderada pela frequência inversa no documento, que é usada para mensurar o quão importante um termo é em um documento (por exemplo a palavra "um" em um conjunto de textos em português aparece várias vezes, apesar de ter uma baixa importância). Ele pode ser calculado pelas expressões:

$$TF(t) = \frac{\# \text{ de aparições de } t \text{ no documento}}{\text{total de termos no documento}} \quad (3.26a)$$

$$IDF(t) = \log \left(\frac{\text{Total de documentos}}{\# \text{ de documentos que contenham } t} \right) \quad (3.26b)$$

$$TF - IDF(t) = TF(t) * IDF(t) \quad (3.26c)$$

O procedimento de obtenção dos vetores de *features* a partir do novo *corpus* pode ser realizado utilizando as bibliotecas `scikit-learn` e `nltk` do Python.

3.5.3 Classificação Manual da Opinião

Com o conjunto de dados obtido em 3.5.2, podemos aplicar os algoritmos descritos no começo do capítulo. Entretanto como também mencionado no começo deste capítulo, problemas de aprendizado supervisionado exigem que o conjunto de dados seja composto não só dos dados, mas também do valor esperado para cada entrada. No caso da classificação da opinião de textos, tal opinião deve ser primeiro atribuída manualmente para que, com posse dessas opiniões, seja possível treinar os algoritmos.

Para facilitar a etapa de classificação manual, foi desenvolvido um sistema online onde cada usuário informa a quantidade de *tweets* que se deseja classificar e consegue classificá-los de forma mais simples. Deu-se a essa ferramenta o nome de CLAM (de Classificador Manual).

O desenvolvimento do CLAM foi motivado pela ausência de ferramentas no Brasil que permitem a colaboração nessa etapa de classificação manual (uma ferramenta comumente usada é o *Amazon Mechanical Turk*, porém na época do desenvolvimento do CLAM não estava disponível no Brasil) em conjunto com a falta de ferramentas gratuitas de uma forma geral, uma vez que até que a maioria das ferramentas existentes são pagas (vide o próprio *Amazon Mechanical Turk*). Por isso priorizou-se construir um código simples para que fosse fácil a modificação da base do sistema por colaboradores externos, que fosse de fácil uso para o usuário final e também de fácil hospedagem do sistema em alguma plataforma como Heroku e Firebase.

O código é de domínio público e está disponível no link: <https://github.com/romaolucas/manual-classifier-helper>

O projeto foi desenvolvido usando a linguagem Python em conjunto do *framework* web Django por já possuir diversas ferramentas integradas não só de gerenciamento do sistema, bem como modelagem do banco de dados e sistema de migração para que possa modificar os modelos de dados já existentes sem precisar realizar um acesso direto à base de dados além de possuir um conjunto de bibliotecas que facilitam o processo de importação

de dados em csv e vasta quantidade de tutoriais de como desenvolver uma aplicação usando Django.

Para a modelagem de dados construiu-se dois modelos: um para *tweets* e outro para as opiniões. Na modelagem, considerou-se que cada usuário irá classificar apenas textos que não possuem uma classificação, não só para evitar ter que lidar com opiniões divergentes em um texto, mas também para garantir um maior número de dados para o treinamento. Uma possível melhoria do sistema seria a possibilidade de mais usuários avaliarem um mesmo conjunto de textos para garantir um consenso na hora de associar uma opinião a um texto.

O CLAM possui o seguinte fluxo para a classificação:

1. Informa a quantidade de *tweets* que se deseja classificar.

Atividades Google Chrome dom, 29 de out, 16:24

(8) Twitter x Inbox - luca x How to get x Bag of Words x CSS Layout x python - Car x Sentiment A x Bem vindo x Lucas

Seguro | https://tweets-classifier.herokuapp.com

Apps GitHub - papers- 0xDE Semantic Domain A Reading List Fo Computer Scien Google NOVACULTURA Oasys Hair (@oasys) Que vídeo mara

Classificador Manual de Tweets (Clam) Classificar Tweets Tweets Classificados

Quanto tweets você deseja classificar?


100

Enviar

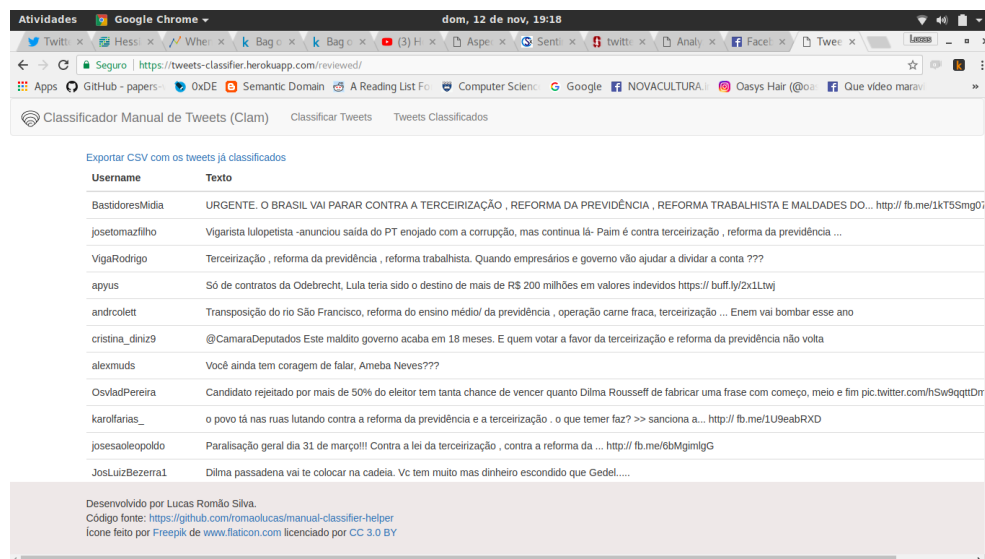
Desenvolvido por Lucas Romão Silva.
Código fonte: <https://github.com/romaolucas/manual-classifier-helper>
Ícone feito por Freepik de www.flaticon.com licenciado por CC 3.0 BY

2. O usuário é levado a uma página com os n *tweets* para classificar. Enquanto o campo da opinião é obrigatório, existe um campo optativo para informar se o dado *tweet* é irônico ou não, uma vez que textos com ironia atrapalham o treinamento por conter palavras positivas sendo usadas de maneira negativa e vice-versa.

20CAPÍTULO 3. MACHINE LEARNING E ANÁLISE DE SENTIMENTOS




3. Uma vez classificados, o usuário é levado a uma página onde é possível ver todos os *tweets* já classificados e também gerar um arquivo csv contendo todos aqueles que não foram marcados como irônicos.

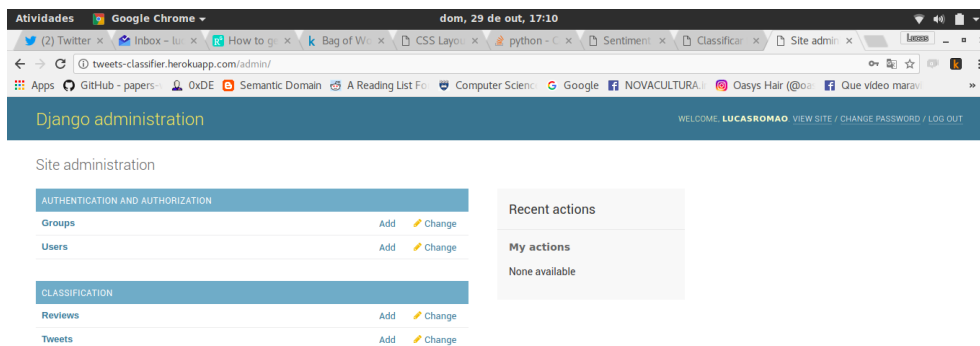


Para um usuário que deseja hospedar a plataforma e usá-la para si, existe também o admin onde é possível importar *tweets* para serem classificados. Abaixo é descrito o fluxo para a importação de novos dados no admin.

1. Realiza o login no sistema utilizando seu usuário e senha de administrador.




2. Selecciona a parte de Tweets na tela principal.




3. Uma vez na parte de visualizar todos os *tweets* já armazenados na base de dados, seleciona a opção de importar no canto superior direito.

22CAPÍTULO 3. MACHINE LEARNING E ANÁLISE DE SENTIMENTOS



4. Na página que segue, basta informar um arquivo .csv, .xls (formato do excel) ou .json contendo nessa ordem: o id do *tweet* (fornecido pelo Twitter), usuário que escreveu, texto, espaço vazio para representar o id que será preenchido automaticamente na hora de importar no banco de dados.



5. Caso todos os dados sejam fornecidos corretamente, será passado a uma nova página para confirmar se deseja importar e, por fim, será redirecionado à página que contém todos os *tweets*.

Capítulo 4

Experimentos

4.1 Descrição dos experimentos

4.2 Análise Exploratória

4.3 Métricas avaliadas

Para a realização dos experimentos, levou-se em consideração três métricas para avaliar a eficiência dos classificadores.

Referências Bibliográficas

- [1] Hoda Korashy Walaa Medhat, Ahmed Hassan. Sentiment analysis algorithms and applications: A survey. *Ain Shams Engineering Journal*, pages 1093–1113, 2014.
- [2] Patrick Paroubek Alexander Pak. Twitter as a corpus for sentiment analysis and opinion mining. *Proceedings of the International Conference on Language Resources and Evaluation*, pages 1320–1326, 2010.
- [3] Martin Ringsquandl and Dušan Petković. Analyzing political sentiment on twitter. *AAAI Spring Symposium*, 2013.
- [4] Jennifer van der Puil et. al Akshat Bakliwal, Jennifer Foster. Sentiment analysis of political tweets: Towards an accurate classifier. *Proceedings of the Workshop on Language in Social Media*, pages 49–58, 2013.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 1 edition, 2006.
- [6] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, pages 273–297, 1995.
- [7] Bing Liu. *Sentiment Analysis and Opinion Mining*. Morgan & Claypool Publishers, 1 edition, 2012.